

Ciencia de Datos Aplicada a la Minería

Introducción a la ciencia de datos con python



Sesión # 2

- *Tipos de datos*
- *Tipos de variables*

Instructor:

➤ *Ph.D. (c) Jorge Lliguizaca Dávila*



Tipos de Datos



¿Ejemplos?

Datos Estructurados (1)

- Son aquellos datos que tienen **tamaño finito y formato**.



caracteres. En esta categoría entran los que se compilan en los tas, los datos de transacciones bancarias, las compras en tiendas

El lenguaje de consulta estructurado (SQL) es un lenguaje de programación para almacenar y procesar información en una base de datos relacional.

Datos Estructurados (2)

- **Creados:** datos generados por nuestros sistemas de una manera predefinida (registros en tablas).
- **Provocados:** datos creados de manera indirecta a partir de una acción previa (valoraciones de restaurantes, películas, empresas, TripAdvisor, ...).
- **Dirigido por transacciones:** datos que resultan al finalizar una acción previa de manera correcta (facturas autogeneradas al realizar una compra, recibo de un cajero automático, etc.).
- **Compilados:** resúmenes de datos de empresa, servicios públicos de interés grupal. Entre ellos nos encontramos con el censo electoral, vehículos matriculados, viviendas públicas, entre otros).
- **Experimentales:** datos generados como parte de pruebas o simulaciones que permitirán validar si existe una oportunidad de negocio.


Datos No Estructurados (1)

- Aquellos datos que **carecen** de un formato determinado. No pueden ser almacenados en una tabla.
- Conviene saber que este tipo de datos no tiene campos fijos y normalmente se tiene poco control sobre ellos. Su manipulación requiere herramientas especializadas, como Hadoop (la más popular) y/o bases de datos NoSQL, entre otras.
- **Capturados:** datos creados a partir del comportamiento de un usuario. Por ejemplo, información biométrica de pulseras de movimiento, aplicaciones de seguimiento de actividades (carrera, ciclismo, natación, etc.), posición GPS.
- **Generados por usuarios:** datos que especifica un usuario (publicaciones en redes sociales, videos

reproducidos en YouTube, búsquedas en Google, entre otros).

Estructurados Vs No Estructurados

What's Hiding in Your Unstructured Data?



Source: Graphic adapted from January 2018 CXPA Presentation "The Why Behind the What," Jim Kitterman




Estructurados Vs No Estructurados

Fuente: <https://k21academy.com/microso@-azure/dp-900/structured-datavs-unstructured-data-vs-semi-structured-data/>

Estructurados Vs No

Estructurados




Fuente: <https://www.altexsoft.com/blog/structured-unstructured-data/>

Datos Semiestructurados


- Poseen organización interna o marcadores que facilita el tratamiento de sus elementos. No pertenecen a bases de datos relacionales.
- **Ejemplos:** XML, HTML o los datos almacenados en bases de datos NoSQL.
- Tienen una cierta estructura, aunque sin llegar a estar totalmente estructurados.

Flujo de Datos




Fuente: <https://www.dataityx.com/wp-content/uploads/2017/03/big-data-flow.png>

Tipos de Datos: Variables




Numeric or
Quantitative

Categorical or
Qualitative





Ordinal





Datos: fuentes y formatos

- Información digital o que es digitalizada para su procesamiento.
- Los datos pueden proporcionarse de distintas formas y en una gran variedad de

formatos.



Fuentes de Datos (1)



Fuente: <https://www.allerin.com/blog/top-5-sources-of-big-data>

Fuente de Datos (2)




Fuente: <https://todobi.com/seleccion-de-las-mejores-free-big-data/>

¿Qué es una Fuente de Datos? (4)

- **Biométricos:** ADN, reconocimiento facial, ...
 - **IoT:** RFID, smart devices, ...
 - **Datos Transacciones:** Facturación, Transferencias, TC, ...
 - **Datos de Geolocalización:** Información espacial. ➤
- Generados por humanos:** Voz, emails, documentos, ➤ **Web**
- y medios sociales:** Clicks, búsquedas, publicaciones,...

Fuente: <https://korporatech.es/los-cinco-tipos-de-fuentes-de-datos/>

Formatos de Datos en Geociencias



Shapefile (.shp)

GeoTIFF (.tif)

KML/KMZ (.kml)

GeoJSON
(.geojson)

Well log formats
(LAS)

SEG-Y (.sgy)

CSV

HDF5

GML (Geography
Markup
Language)

input.DATA (.txt)

Mejores Prácticas para la Gestión de Datos Geocientíficos

1. Establecer una Estrategia de Gestión de Datos

- Definir objetivos claros
- Identificar las fuentes de datos
- Establecer estándares de calidad

2. Crear una Base de Datos Centralizada

Seleccionar un sistema de gestión de bases de datos (SGBD) adecuado

Diseñar una estructura de datos lógica
Implementar controles de acceso

3. Asegurar la Calidad de los Datos

- Validación de datos
- Limpieza de datos
- Metadatos

Mejores Prácticas para la Gestión de Datos Geocientíficos

4. Utilizar Herramientas de Visualización y Análisis

- Sistemas de Información Geográfica (SIG)
- Software de modelado y simulación
- Herramientas de análisis estadístico

- Herramientas de soporte de decisiones

5. Compartir y Colaborar

- Establecer protocolos de intercambio de datos (tomando en consideración la seguridad de los mismos) • Utilizar estándares de datos abiertos

6. Realizar Copias de Seguridad y Recuperación de Desastres

- Establecer un plan de respaldo
- Realizar pruebas de recuperación

7. Capacitar al Personal

- Proporcionar capacitación

Herramientas y Tecnologías Útiles

Sistemas de Información Geográfica (SIG): ArcGIS, QGIS Bases

de datos relacionales: MySQL, SQLite, PostgreSQL, Oracle

Nubes: AWS, Azure, Google Cloud

Herramientas de análisis de datos: Python, R

Software de modelado geológico: Leapfrog, Vulcan,

Micromine **Modelos de lenguaje generativos:** ChatGPT,

GeologyOracle

Referencias

- *Unpingco, J. (2021). Python Programming for Data Analysis. Springer*
- *Zelle, J. M. (2010). Python Programming: An Introduction to Computer Science. Franklin, Beedle & Associates Inc.*
- *Datacamp Courses*

Créditos: Freddy Paul Carrión Maldonado