

Ciencia de Datos Aplicada a la Minería

Manejo y preprocesamiento de datos



Sesión 3 & 4

Limpieza de datos

- *Problemas comunes*
- *Problemas de datos categóricos y texto*


Instructor:

➤ *Ph.D. (c) Jorge Lliguizaca Dávila*



Preprocesamiento de Datos -

Ciclo




Limpieza de Datos - Pasos




Fuente: KDNuggets

¿Por qué es necesario limpiar los datos?



¿Por qué es necesario limpiar los datos?



Garbage in Garbage out

Limpieza de Datos - Inconsistencias



- Restricciones de tipos de datos
- Restricciones de rangos de datos
- Restricciones de unicidad



- Restricciones de categorías
- Limpieza de datos de texto



- Uniformidad (homogeneidad)
- Validación cruzada

- Integridad (Compleitud)

Problemas Comunes de Datos – Restricciones de Tipos

Datatype	Example
Text data	First name, last name, address ...
Integers	# Subscribers, # products sold ...
Decimals	Temperature, \$ exchange rates ...
Binary	Is married, new customer, yes/no, ...
Dates	Order dates, ship dates ...
Categories	Marriage status, gender ...

Python data type
<code>str</code>
<code>int</code>
<code>float</code>
<code>bool</code>
<code>datetime</code>
<code>category</code>

de Datos

Problemas Comunes de Datos – Restricciones de

Tipos de Datos

Transformación de Datos:

```
# Import CSV file and output header  
sales = pd.read_csv('sales.csv')  
sales.head(2)
```

	SalesOrderID	Revenue	Quantity
0	43659	23153\$	12
1	43660	1457\$	2

```
# Get data types of columns  
sales.dtypes
```

```
SalesOrderID    int64  
Revenue         object  
Quantity        int64  
dtype: object
```

Problemas Comunes de Datos – Restricciones de Tipos

de Datos

Transformación de Datos. Strings (str) a Enteros (int):



Problemas Comunes de Datos – Restricciones de Tipos de Datos

Transformación de Datos: ¿Variable numérica o categórica?



Problemas Comunes de Datos – Restricciones de Tipos de Datos

Transformación de Datos:



Problemas Comunes de Datos – Restricciones de Rangos de Datos

¿Pueden existir futuras inscripciones o suscripciones?



Problemas Comunes de Datos – Restricciones de Rangos de Datos

¿Cómo tratar los datos fuera de rango?

Problemas Comunes de Datos – Restricciones de

Rangos de Datos





Problemas Comunes de Datos – Restricciones de Rangos de Datos

1. Eliminar datos fuera de rango:



Problemas Comunes de Datos – Restricciones de Rangos de Datos

2. Establecer valor máximo personalizado:



Problemas Comunes de Datos – Restricciones de Unicidad

¿Qué son los valores duplicados?

Todas las columnas tienen los mismos valores




La mayoría de las columnas tienen los mismos valores



valor

Problemas Comunes de Datos – Restricciones de Unicidad

¿Por qué ocurren los problemas de unicidad?



Problemas Comunes de Datos – Restricciones de
Unicidad

¿Cómo encontrar valores duplicados?



Problemas Comunes de Datos – Restricciones de

Unicidad

¿Cómo encontrar valores duplicados?



Problemas Comunes de Datos – Restricciones de

Unicidad

¿Cómo encontrar filas duplicados?

- Utilizar el método **duplicated()**.
- ✓ **subset:** Lista de columnas para revisar duplicados.
- ✓ **keep:** Mantener el primero (“**first**”), último (“**last**”) o todos (**False**) los valores duplicados.



Problemas Comunes de Datos – Restricciones de

Unicidad

¿Cómo encontrar filas duplicados?



Problemas Comunes de Datos – Restricciones de

Unicidad

¿Cómo encontrar filas duplicados?



Problemas Comunes de Datos – Restricciones de Unicidad

¿Cómo encontrar filas duplicados?



Problemas Comunes de Datos – Restricciones de Unicidad

¿Cómo encontrar filas duplicados?



Problemas Comunes de Datos – Restricciones de Unicidad

¿Cómo tratar valores duplicados?



Problemas Comunes de Datos – Restricciones de Unicidad

¿Cómo tratar valores duplicados?

- Utilizar el método **drop_duplicates()**.
- ✓ **subset:** Lista de columnas para revisar duplicados.
- ✓ **keep:** Mantener el primero ("**first**"), último ("**last**") o todos (**False**) los valores duplicados.
- ✓ **inplace:** Eliminar filas duplicadas directamente.



Problemas Comunes de Datos – Restricciones de Unicidad

¿Cómo tratar valores duplicados?



Problemas Comunes de Datos – Restricciones de Unicidad

¿Cómo tratar valores duplicados?

➤ Utilizar métodos `.groupby( )` y `.agg( )`.



Limpieza de Datos



- Restricciones de tipos de datos
- Restricciones de rangos de datos
- Restricciones de unicidad



- Restricciones de categorías
- Limpieza de datos de texto



- Uniformidad (homogeneidad)
- Validación cruzada
- Integridad (Compleitud)

Problemas de Datos Categóricos – Restricciones de Categorías

Conjunto finito predefinido de categorías



Problemas de Datos Categóricos – Restricciones de Categorías

¿Por qué pueden ocurrir estos problemas?



Problemas de Datos Categóricos – Restricciones de Categorías

¿Cómo podemos tratar este tipo de problemas?



Problemas de Datos Categóricos – Restricciones de Categorías

Ejemplo de categoría incorrecta



Problemas de Datos Categóricos – Restricciones de Categorías

¿Cómo podemos tratar este tipo de problemas?



Problemas de Datos Categóricos – Restricciones de Categorías



mas?

Retorna solamente las filas que
contienen **Z+**

Problemas de Datos Categóricos – Restricciones de



emas?

Retorna todas las filas, excepto
las que contienen **Z+**, **B+** y **AB-**

Problemas de Datos Categóricos – Restricciones de Categorías

Encontrar categorías inconsistentes



Problemas de Datos Categóricos – Restricciones de Categorías

Eliminar categorías inconsistentes



Problemas de Datos Categóricos – Restricciones de Categorías

¿Qué tipos de errores se pueden presentar?

1. Valores inconsistentes

- Campos inconsistentes: “married”, “Maried”, “UNMARRIED”, “not married”.
- Espacios en blanco: “ married”, “ married ”.

2. Muchas categorías

- Crear nuevos grupos: 0-20k, 20-40k categorías.
- Reducción de categorías existentes.

3. Asegurarse que la variable es de tipo categórica

Problemas de Datos Categóricos – Restricciones de Categorías

1. Tratar Valores Inconsistentes

“married”, “Married”, “UNMARRIED”, “unmarried”



Problemas de Datos Categóricos – Restricciones de Categorías

1. Tratar Valores Inconsistentes



Problemas de Datos Categóricos – Restricciones de Categorías

1. Tratar Valores Inconsistentes



Problemas de Datos Categóricos – Restricciones de Categorías

1. Tratar Valores Inconsistentes

“married ”, “married”, “unmarried”, “ unmarried”



Problemas de Datos Categóricos – Restricciones de Categorías

1. Tratar Valores Inconsistentes

“married ”, “married”, “unmarried”, “ unmarried”



Problemas de Datos Categóricos – Restricciones de Categorías

2. Creación de Categorías



Problemas de Datos Categóricos – Restricciones de Categorías

2. Creación de Categorías



Problemas de Datos Categóricos – Restricciones de Categorías

2. Reducción de Categorías

- **Columna `operating_system`:** “Microsoft”, “MacOS”, “IOS”, “Android”, “Linux”.
- **Columna podría convertirse en:** “DesktopOS”, “MobileOS”



Problemas de Datos Categóricos – Limpieza de Datos de

Texto



Problemas comunes

- **1. Inconsistencia de datos:**
 - +96171679912 o 0096171679912
- **2. Violación de longitudes establecidas** ○
Contraseñas necesitan tener al menos 8 caracteres.
- **3. Errores de tipeo**
 - +961.71.679912

Problemas de Datos Categóricos – Limpieza de Datos de Texto

Ejemplo:



Problemas de Datos Categóricos – Limpieza de Datos de Texto

Solución:



Problemas de Datos Categóricos – Limpieza de Datos de Texto

Solución:




Problemas de Datos Categóricos – Limpieza de Datos de Texto

Solución:



Problemas de Datos Categóricos – Limpieza de Datos de Texto

Solución:



Referencias

- *Unpingco, J. (2021). Python Programming for Data Analysis. Springer*
- *Zelle, J. M. (2010). Python Programming: An Introduction to Computer Science. Franklin, Beedle & Associates Inc.*
- *Datacamp Courses*

Créditos: Freddy Paul Carrión Maldonado