

Análisis Exploratorio de Datos (EDA)




FUNDAMENTOS TEÓRICOS DE ESTADÍSTICA,
OBJETIVOS Y ALCANCES DEL ANÁLISIS

Fundamentos Básicos de Estadística Aplicada a Geoquímica

¿Por qué necesitamos estadística en exploración?

Los datos geoquímicos no son solo números; son señales que reflejan procesos geológicos.



En exploración:

Trabajamos con concentraciones (ppm, %).

Hay alta variabilidad natural.

Existen valores extremos (anomalías).

Las distribuciones rara vez son normales.



La estadística permite:

Describir la población de datos.

Detectar patrones.

Identificar anomalías.

Reducir incertidumbre en la toma de decisiones.

Tipos de variables en geoquímica

Variables cuantitativas continuas

Ejemplo:

- Cu (% ppm)
- Au (g/tn)
- Mo (%)

Escala de razón:

- Tienen cero absoluto.
- Permiten operaciones matemáticas válidas.
- Permiten análisis estadísticos formales.

B	C	D	E	AL	AM	AN	AO	AP	AQ	AR	AS
Sample	Alias	Type	N Dup	La (mg/kg)	Li (mg/kg)	Lu (mg/kg)	Mg (%)	Mn (mg/kg)	Mo (mg/kg)	Na (%)	Nb (mg/kg)
SuWB0001	SuWB0001	Original		38.30	52.10	0.20	0.81	438.00	1.09	1.84	9.80
SuWB0002	SuWB0002	Duplicado	SuWB0001	37.00	52.80	0.21	0.82	435.00	0.93	1.93	10.30
SuWB0003	SuWB0003	Original		34.00	31.50	0.13	0.42	307.00	1.15	2.18	7.70
SuWB0004	SuWB0004	Original		52.30	42.00	0.18	0.56	449.00	1.12	2.15	11.00
SuWB0005	SuWB0005	Blanco		0.10	3.30	0.01	0.01	51.00	1.55	0.10	0.05
SuWB0006	SuWB0006	Original		33.30	40.80	0.16	0.54	355.00	1.01	2.08	8.90
SuWB0007	SuWB0007	Original		48.50	52.80	0.21	0.68	569.00	1.59	1.89	13.30
SuWB0008	SuWB0008	Estandar		3.50	10.90	0.02	0.32	29860.00	4.53	0.01	1.00
SuWB0009	SuWB0009	Original		36.30	147.20	0.25	0.94	421.00	1.40	1.42	11.00
SuWB0010	SuWB0010	Original		37.20	38.20	0.17	0.63	413.00	1.27	2.06	9.50
SuWB0011	SuWB0011	Original		40.30	42.30	0.21	0.87	562.00	1.46	1.97	11.10
SuWB0012	SuWB0012	Original		36.40	196.80	0.23	1.07	412.00	2.10	1.94	11.30
SuWB0013	SuWB0013	Original		32.70	58.20	0.19	0.71	442.00	1.03	2.04	8.90
SuWB0014	SuWB0014	Original		61.10	66.60	0.22	0.77	597.00	1.67	1.87	13.70
SuWB0015	SuWB0015	Original		36.50	58.80	0.16	0.51	407.00	1.40	2.02	10.80
SuWB0016	SuWB0016	Original		45.90	50.80	0.22	0.79	602.00	1.61	2.10	11.80
SuWB0017	SuWB0017	Original		48.10	46.30	0.25	0.78	631.00	2.19	2.17	13.10
SuWB0018	SuWB0018	Duplicado	SuWB0017	41.90	40.50	0.22	0.76	487.00	1.75	2.14	11.40
SuWB0019	SuWB0019	Original		44.70	52.50	0.22	0.78	598.00	1.65	2.06	12.60
SuWB0020	SuWB0020	Original		47.30	46.70	0.21	0.78	567.00	2.01	2.10	12.40
SuWB0021	SuWB0021	Original		39.50	40.70	0.19	0.73	491.00	1.76	2.11	11.30
SuWB0022	SuWB0022	Original		70.70	44.30	0.24	0.75	700.00	2.20	1.94	17.30

Medidas de tendencia central

MEDIA ARITMÉTICA

Características

- Minimiza la suma de cuadrados.
- Sensible a valores extremos.

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n} = \frac{1}{n} \sum_{i=1}^n x_i$$


MEDIANA

Características

- Valor central cuando los datos están ordenados.
- Robusta frente a outliers.
- Mejor representativa e

$$M = \begin{cases} x_{\frac{n+1}{2}}, & \text{si } n \text{ es impar} \\ \frac{x_{\frac{n}{2}} + x_{\frac{n}{2}+1}}{2}, & \text{si } n \text{ es par} \end{cases}$$

CUÁL ES LA DIFERENCIA ENTRE LA MEDIA Y LA MEDIANA EN ARITMÉTICA



Medidas de dispersión

VARIANZA

Mide la dispersión promedio de los datos respecto a la media, utilizando los cuadrados de las desviaciones. Se expresa en unidades al cuadrado.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

DESVIACIÓN ESTÁNDAR

Es la raíz cuadrada de la varianza. También mide dispersión, pero se expresa en las mismas unidades que los datos originales, lo que facilita su interpretación.

- Problema:
Si la distribución es lognormal, la desviación estándar puede no ser representativa.

Rango intercuartílico (IQR)

Definición


- $IQR = Q3 - Q1$

Donde:

- $Q1$ = percentil 25
- $Q3$ = percentil 75

Propiedades:

- No depende de valores extremos.
- Base matemática del boxplot.
- Excelente para detectar anomalías preliminares.




Distribuciones de datos

DISTRIBUCIÓN NORMAL

- Simétrica.
- Rara en concentraciones brutas.

DISTRIBUCIÓN LOGNORMAL

- Asimétrica positiva.
- Muy común en concentraciones elementales.





Conexión con exploración mineral

Por qué esto importa?

Porque antes de:


- Hacer mapas,
- Interpolar,
- Aplicar PCA,
- Construir modelos predictivos,



Necesitamos saber ...

- ¿Cuál es la distribución real?
- ¿Hay múltiples poblaciones?
- ¿Existen valores extremos reales o errores?
- ¿La variable necesita transformación?

INTRODUCCIÓN AL EDA (Exploratory Data Analysis)



¿Qué es el EDA?

El **Exploratory Data Analysis** (EDA) es el conjunto de técnicas estadísticas y gráficas utilizadas para:

Comprender la estructura de un conjunto de datos.

Detectar patrones.

Identificar valores atípicos.

Evaluar supuestos antes de aplicar modelos formales.



Es una etapa **previa al modelado predictivo o geoestadístico.**

¿Por qué el EDA es crítico en exploración geoquímica?

En exploración mineral trabajamos con:



Objetivos del EDA en geoquímica

Objetivos


Describir la distribución de cada elemento.	Identificar poblaciones (background vs anomalía).	Detectar valores extremos.	Evaluar necesidad de transformación.	Analizar relaciones entre elementos.	Preparar datos para métodos multivariados (PCA, clustering, modelos predictivos).
---	---	----------------------------	--------------------------------------	--------------------------------------	---

El EDA permite entender asociaciones metalogénicas preliminares.


EDA como puente entre geología y estadística

1. Afinidad hidrotermal
2. Sistema tipo pórfido

Podría sugerir



Etapas estructuradas del EDA



Fundamento estadístico del EDA

- El EDA se basa en:



Estadística
descriptiva



Teoría de
distribuciones



Medidas robustas



Correlación y
covarianza



Transformaciones
matemáticas

Diferencia entre EDA e inferencia estadística

EDA	Inferencia
Explora	Confirma
Visualiza	Testea hipótesis
Flexible	Formal
Descriptivo	Probabilístico





En exploración mineral, el EDA es previo a:

Geoestadística



Kriging

Modelos predictivos

Machine learning



¿Por qué las herramientas gráficas son esenciales?



Histograma

¿Qué representa?

Un histograma es una estimación empírica de la función de densidad de probabilidad.



Divide el rango de datos en intervalos (bins) y cuenta frecuencias.

Matemáticamente:

Si tenemos "n" datos, el histograma aproxima la distribución subyacente.

¿Cómo se interpreta?

- Simétrico → posible normalidad
- Cola derecha → sesgo positivo (común en geoquímica)
- Múltiples picos → mezcla de poblaciones




Boxplot

Elementos:

- Q1 (percentil 25)
- Mediana
- Q3 (percentil 75)
- $IQR = Q3 - Q1$

¿Qué permite ver?

- Dispersión
- Sesgo
- Valores extremos
- Comparación entre elementos.



Q1 – 1.5IQR y Q3 + 1.5IQR

Scatter Plot

Cada punto representa :


- (x_i, y_i)
- Mediana

Base matemática:

- Covarianza y correlación.

¿Qué permite
identificar?

- Relación lineal
- Tendencias no lineales
- Agrupamientos
- Subpoblaciones



TENDENCIAS? RELACION?


Interpretación combinada (Pairplots)

Combina:

- Scatter plots entre todas las variables.
- Histogramas o distribuciones en la diagonal.

Interpretación en geoquímica

- Si Cu, Mo y Au muestran correlaciones coherentes entre sí,
- Y además comparten asimetría similar,
- Podría indicar asociación metalogenética.



Errores comunes en interpretación gráfica



Confundir outlier con error analítico

Un valor extremo puede deberse a:

- Error de laboratorio.
- Contaminación.
- Error de digitación.
- O anomalía geológica real.



Interpretar correlación como causalidad

Si Cu y Mo están correlacionados:

No significa que uno cause al otro.

Significa que:

- Podrían compartir un proceso común.
- Podrían estar controlados por la misma fase mineral.
- Podrían estar asociados a un mismo evento hidrotermal.



Analizar variables con diferentes órdenes de magnitud sin estandarizar

Comparar:

- Cu (ppm)
- Au (ppb)
- HREE (ppm)

Sin normalización puede generar sesgo en análisis multivariado.

La escala domina el resultado.


¿Qué significa que dos elementos estén relacionados?

Quando observamos en un scatter que Cu aumenta junto con Mo, estamos viendo una **relación estadística**.

Pero necesitamos cuantificarla.

Para eso usamos:

1. **Covarianza:** no estandarizada.
2. **Correlación:** adimensional y permite comparar relaciones entre diferentes pares de elementos



Heatmap

Representación gráfica de la matriz.

Cuando tenemos múltiples elementos:

Cu, Mo, Au, Pb, Zn, HREE...


Calculamos correlación entre todos los pares.

Resultado:

Una matriz simétrica.


Propiedades:

- Diagonal = 1
- Matriz cuadrada
- $r(X,Y) = r(Y,X)$




Interpretación geológica responsable


CORRELACIÓN ALTA



LIMITACIONES IMPORTANTES



¿Por qué debemos unificar escala?




Z-score (Estandarización)

Definición matemática:



$$Z = \frac{x - \mu}{\sigma}$$

En programación (Python, por ejemplo), el procedimiento automático más usado es: **StandardScaler**

Este implementa exactamente el Z-score.



INTRODUCCIÓN AL EDA (Exploratory Data Analysis)



Carga del Dataset Geoquímico

Procedimiento

- Se importan las librerías fundamentales: pandas para manejo de datos, numpy para operaciones numéricas y os para manejo de rutas.
- Se carga el archivo Excel `dataset_geoquimico.xlsx` en un DataFrame de pandas usando ruta relativa.
- Se visualizan las primeras filas del dataset con `df.head()` para verificar que se cargó correctamente y observar la estructura inicial de los datos.

```
import pandas as pd
import numpy as np
import os

# Cargar dataset (ruta relativa)
df = pd.read_excel("datos/dataset_geoquimico.xlsx")

# Mostrar primeras filas
df.head()
```

Limpieza y Preparación del Dataset

Procedimiento

- Se eliminan espacios en los nombres de columnas con `df.columns.str.strip()` para evitar errores al manipular los datos.
- Se define una lista de elementos geoquímicos de interés para análisis posterior: cobre, molibdeno, oro, arsénico, zinc, plomo, plata y tierras raras (Cu_ppm, Mo_ppm, Au_ppm, etc.).
- Se eliminan filas con valores faltantes usando `df.dropna(inplace=True)` para asegurar un dataset completo y consistente.
- Se guarda el dataset limpio en una nueva ubicación (datos_limpios/dataset_geoq_limpio.xlsx) para uso en análisis posteriores.

```
# Limpiar nombres de columnas
df.columns = df.columns.str.strip()

# Definir elementos
elementos = ["Cu_ppm", "Mo_ppm", "Au_ppm", "As_ppm",
             "Zn_ppm", "Pb_ppm", "Ag_ppm",
             "Ce_ppm", "La_ppm", "Nd_ppm"]

# Eliminar filas con valores faltantes
df.dropna(inplace=True)

# Guardar dataset limpio (ruta relativa)
df.to_excel("datos_limpios/dataset_geoq_limpio.xlsx", index=False)
```

Estadísticas Descriptivas del Dataset

Procedimiento

Se utiliza `df.describe()` para generar un resumen estadístico de las columnas numéricas del dataset.

Se obtiene información como:

- **Cuenta (count):** número de valores no nulos por columna.
- **Media (mean):** valor promedio de cada variable.
- **Desviación estándar (std):** dispersión de los datos alrededor de la media.
- **Valores mínimos y máximos (min, max)** y los **cuartiles (25%, 50%, 75%)** para evaluar la distribución de los datos.

```
# Limpiar nombres de columnas
df.columns = df.columns.str.strip()

# Definir elementos
elementos = ["Cu_ppm", "Mo_ppm", "Au_ppm", "As_ppm",
             "Zn_ppm", "Pb_ppm", "Ag_ppm",
             "Ce_ppm", "La_ppm", "Nd_ppm"]

# Eliminar filas con valores faltantes
df.dropna(inplace=True)

# Guardar dataset limpio (ruta relativa)
df.to_excel("datos_limpios/dataset_geoq_limpio.xlsx", index=False)

df.describe()
```


Distribución de los Elementos Principales

Procedimiento

- Se seleccionan los elementos geoquímicos más relevantes: cobre, molibdeno, oro, arsénico y plata (Cu_ppm, Mo_ppm, Au_ppm, As_ppm, Ag_ppm).
- Se crea un histograma para cada elemento usando matplotlib.pyplot para visualizar la distribución de los valores.
- Se definen 20 intervalos (bins=20) y color gris para claridad visual.
- Se agregan título, etiquetas de ejes y cuadrícula (plt.grid(alpha=0.5)) para facilitar la interpretación de la frecuencia de los datos.

```
import matplotlib.pyplot as plt

principales = ["Cu_ppm", "Mo_ppm", "Au_ppm", "As_ppm", "Ag_ppm"]

for el in principales:
    plt.hist(df[el], bins=20, color="Gray")
    plt.grid(alpha=0.5)
    plt.title(f"Histograma {el}")
    plt.xlabel(el)
    plt.ylabel("Frecuencia")
    plt.show()
```

Histograma Logarítmico de Cobre

Procedimiento

- Se aplica **transformación logarítmica ($\log_{10}$)** a Cu_ppm para reducir la asimetría y la influencia de valores extremos.
- Se agrega +1 para evitar problemas con ceros.
- El resto del código (histograma, color, cuadrícula, títulos) permanece igual, solo cambia la **escala de los datos** que se representa.

```
plt.hist(np.log10(df["Cu_ppm"]+1), bins=20, color="gray")  
plt.grid(alpha=0.5)  
plt.title("Histograma log(Cu_ppm)")  
plt.show()
```

Scatter plots

Procedimiento

- Se utiliza un **diagrama de dispersión (scatter plot)** para visualizar la relación entre Cu_ppm y Mo_ppm.
- Cada punto representa una muestra del dataset con sus valores de cobre y molibdeno.
- Se etiquetan los ejes para claridad (xlabel, ylabel).
- Permite **identificar correlaciones, tendencias o agrupamientos** que no se observan en histogramas individuales.

```
plt.scatter(df["Cu_ppm"], df["Mo_ppm"])  
plt.xlabel("Cu_ppm")  
plt.ylabel("Mo_ppm")  
plt.show()
```

```
plt.scatter(df["Cu_ppm"], df["Au_ppm"])  
plt.xlabel("Cu_ppm")  
plt.ylabel("Au_ppm")  
plt.show()
```

Boxplots de Elementos Geoquímicos

Procedimiento

- Se utiliza **seaborn.boxplot** para visualizar la **distribución, mediana y valores atípicos** de todos los elementos seleccionados (elementos).
- Se ajusta el tamaño de la figura (`figsize=(10,6)`) y la rotación de los nombres de columnas (`xticks(rotation=45)`) para mejorar la legibilidad.
- Se guarda la figura en alta resolución (`dpi=300`) para documentación o presentación.
- Permite **comparar la dispersión y detectar outliers** de manera rápida entre todos los elementos sin necesidad de múltiples histogramas.

```
import seaborn as sns

plt.figure(figsize=(10,6))

sns.boxplot(data=df[elementos])

plt.xticks(rotation=45)
plt.tight_layout()

plt.savefig("figuras/boxplot_sin_normalizar.png", dpi=300)

plt.show()
```

Normalización de los Elementos Geoquímicos

Procedimiento

- Se seleccionan solo las columnas numéricas de interés (elementos) para el escalado.
- Se utiliza **StandardScaler** de **sklearn** para **normalizar los datos**, transformándolos a media 0 y desviación estándar 1.
- Se crea un nuevo DataFrame (**df_scaled**) con los valores escalados, manteniendo los nombres de las columnas originales.
- Esta normalización es útil para **comparar variables en la misma escala** y preparar los datos para análisis estadísticos o modelado.

```
from sklearn.preprocessing import StandardScaler

# Seleccionar solo columnas numéricas
df_geoquimico = df[elementos].copy()

scaler = StandardScaler()

df_scaled = scaler.fit_transform(df_geoquimico)

df_scaled = pd.DataFrame(df_scaled, columns=elementos)
```

Boxplots de Elementos Normalizados

Procedimiento

- Se genera un **boxplot** de los elementos después de la normalización (`df_scaled`) para comparar la dispersión en la **misma escala**.
- Se ajusta el tamaño de la figura (`figsize=(10,6)`) y la rotación de las etiquetas (`xticks(rotation=45)`) para mejorar la legibilidad.
- Se guarda la figura en alta resolución (`dpi=300`).
- Permite **visualizar de manera uniforme la mediana, rango y outliers** de todos los elementos, facilitando la comparación directa entre variables.

```
import seaborn as sns

plt.figure(figsize=(10,6))

sns.boxplot(data=df_scaled)

plt.xticks(rotation=45)
plt.tight_layout()

plt.savefig("figuras/boxplot_normalizado.png", dpi=300)

plt.show()
```

Pairplot de Elementos Principales

Procedimiento

- Se generan **gráficos de dispersión entre todas las combinaciones** de Cu_ppm, Mo_ppm, Au_ppm y As_ppm.
- La diagonal muestra la **distribución de cada variable**, mientras que las demás gráficas muestran **relaciones bivariadas** entre pares de elementos.
- Útil para **detectar patrones, agrupamientos o posibles correlaciones** de manera visual y conjunta.

```
sns.pairplot(df[["Cu_ppm", "Mo_ppm", "Au_ppm", "As_ppm"]])  
plt.savefig("figuras/pairplot.png", dpi=300)  
plt.show()
```

Matriz de correlación Heatmap

Procedimiento

Se calcula la **correlación de Pearson** entre los elementos (`df_geoquimico.corr(method="pearson")`) para medir la relación lineal entre pares de variables.

Se utiliza `sns.heatmap` para representar visualmente estas correlaciones:

- Los valores se muestran dentro de cada celda (`annot=True`) con dos decimales (`fmt=".2f"`).
- Se aplica un **mapa de color coolwarm** para distinguir correlaciones positivas y negativas.

Permite **identificar rápidamente fuertes correlaciones o relaciones inversas** entre elementos geoquímicos.

```
corr = df_geoquimico.corr(method="pearson")

plt.figure(figsize=(8,6))

sns.heatmap(
    corr,
    annot=True,
    cmap="coolwarm",
    fmt=".2f"
)

plt.xticks(rotation=45)
plt.yticks(rotation=0)
plt.tight_layout()

plt.savefig("figuras/heatmap.png", dpi=300, bbox_inches="tight")

plt.show()
```

Muchas Gracias!